Nie ma czegoś takiego jak przegrany w kasynie, są tylko ludzie, którzy wyszli za wcześnie

$P(A) > 0$

gdzie A - szansa na zielone 100 razy pod rząd

Rachunek prawdopodobieństwa



Znowu te cholerne kule!



co ty tam odpierdalasz z tymi rękami?



Po co ci syn, jak możesz obstawić pewniaczka i wygrać cały dom dziecka

Skrypt do wykładu prof. Jacka Małeckiego
bez oznaczenia chronologii wykładu,
wykonane przez Szymona Gazińskiego

Spis treści

1 Aksjomatyczna definicja prawdopodobieństwa **1**
- 1.1 Przestrzeń probabilistyczna . . . 1
- 1.2 Zbiory borelowskie i miara Lebesgue'a . . . 2
- 1.3 Prawdopodobieństwo geometryczne . . . 2
- 1.4 Przykład: suma dwóch losowanych liczb . . . 3
- 1.5 Własności prawdopodobieństwa . . . 4

2 Prawdopodobieństwo warunkowe **6**
- 2.1 Definicja i podstawowe własności . . . 6
- 2.2 Prawdopodobieństwo całkowite . . . 7
- 2.3 Wzór Bayesa . . . 9

3 Niezależność **11**
- 3.1 Niezależność dwóch zdarzeń . . . 11
- 3.2 Niezależność rodzin zdarzeń . . . 12
- 3.3 Własności niezależności . . . 13
- 3.4 Schemat Bernoulliego . . . 14
- 3.5 Granice ciągów zdarzeń . . . 14
- 3.6 Lemat Borela–Cantellego . . . 15

4 Zmienne losowe **17**
- 4.1 Definicja i mierzalność . . . 17
- 4.2 σ-ciało generowane przez zmienną losową . . . 18
- 4.3 Niezależność zmiennych losowych . . . 18
- 4.4 Układy π i λ . . . 19
- 4.5 Funkcje niezależnych zmiennych losowych . . . 20

5 Rozkłady zmiennych losowych **23**
- 5.1 Rozkład prawdopodobieństwa . . . 23
- 5.2 Rozkłady dyskretne . . . 25

Rozdział 1

Aksjomatyczna definicja prawdopodobieństwa

1.1 Przestrzeń probabilistyczna

Definicja 1.1. *Przestrzenią probabilistyczną* nazywamy trójkę $(\Omega, \mathcal{F}, \mathbb{P})$, gdzie:

1) Ω jest niepustym zbiorem, zwanym *przestrzenią stanów elementarnych*;

2) $\mathcal{F}$ jest rodziną podzbiorów Ω taką, że:

$$\begin{aligned} &\varnothing \in \mathcal{F}, \\ &A \in \mathcal{F} \implies A^c \in \mathcal{F}, \\ &A_1, A_2, \ldots \in \mathcal{F} \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}; \end{aligned}$$

3) $\mathbb{P}\colon \mathcal{F} \to [0,1]$ jest funkcją spełniającą warunki:

$$\mathbb{P}(\Omega) = 1, \tag{1.1}$$

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n), \tag{1.2}$$

przy czym wzór (1.2) obowiązuje dla każdej rodziny $A_1, A_2, \ldots \in \mathcal{F}$ zdarzeń parami rozłącznych, czyli $A_i \cap A_j = \varnothing$ dla $i \neq j$.

Rodzinę $\mathcal{F}$ nazywamy *σ-ciałem*, a jej elementy *zdarzeniami*. Funkcję $\mathbb{P}$ nazywamy *prawdopodobieństwem*. Warunek (1.2) to *przeliczalna addytywność*.

Uwaga 1.1. Przyjmujemy następującą terminologię:

1) $\omega \in \Omega$ jest stanem elementarnym.

2) Zdarzenia $A, B \in \mathcal{F}$ *wykluczają się*, jeżeli $A \cap B = \varnothing$.

3) $A^c = \Omega \setminus A$ jest *zdarzeniem przeciwnym* do zdarzenia A.

4) $\varnothing$ jest *zdarzeniem niemożliwym*, a Ω jest *zdarzeniem pewnym*.

Fakt 1.1. *Prawdopodobieństwo zdarzenia niemożliwego wynosi zero:*

$$\mathbb{P}(\varnothing) = 0.$$

1.2 Zbiory borelowskie i miara Lebesgue'a

Definicja 1.2. *σ-ciałem zbiorów borelowskich* na $\mathbb{R}$ (odpowiednio na $\mathbb{R}^2$ lub $\mathbb{R}^n$) nazywamy najmniejsze σ-ciało zawierające wszystkie zbiory otwarte. Oznaczamy je przez $\mathcal{B}(\mathbb{R})$ (odpowiednio $\mathcal{B}(\mathbb{R}^2)$ lub $\mathcal{B}(\mathbb{R}^n)$). Na prostej wystarczy rozważać otwarte przedziały (a, b). Elementy tego σ-ciała nazywamy *zbiorami borelowskimi.*

Na przestrzeni $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ istnieje miara λ taka, że

$$\lambda\Big((a,b)\Big) = b - a \qquad \text{dla } a < b.$$

Jest to *miara Lebesgue'a.* Mierzy ona długość i spełnia warunek przeliczalnej addytywności:

$$\lambda\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \lambda(A_n)$$

dla zbiorów borelowskich A_n parami rozłącznych.

Fakt 1.2. *Każdy zbiór jednopunktowy ma miarę Lebesgue'a równą zero:*

$$\lambda(\{x\}) = 0 \qquad \textit{dla każdego } x \in \mathbb{R}.$$

W szczególności $\lambda(\mathbb{Q}) = 0$.

Istotnie, zbiór liczb wymiernych jest przeliczalny. Jeśli $\mathbb{Q} = \{q_1, q_2, \ldots\}$, przy czym liczby q_i są różne, to

$$\lambda(\mathbb{Q}) = \lambda\left(\bigcup_{i=1}^{\infty} \{q_i\}\right) = \sum_{i=1}^{\infty} \lambda(\{q_i\}) = 0.$$

1.3 Prawdopodobieństwo geometryczne

Niech $\Omega \subseteq \mathbb{R}$ będzie zbiorem borelowskim, dla którego $0 < \lambda(\Omega) < \infty$. Przyjmujemy

$$\mathcal{F} = \{A \cap \Omega : A \in \mathcal{B}(\mathbb{R})\}.$$

Dla każdego $B \in \mathcal{F}$ definiujemy

$$\mathbb{P}(B) = \frac{\lambda(B)}{\lambda(\Omega)}. \tag{1.3}$$

W ten sposób otrzymujemy przestrzeń probabilistyczną $(\Omega, \mathcal{F}, \mathbb{P})$.

Analogicznie, dla borelowskiego zbioru $\Omega \subseteq \mathbb{R}^2$ o dodatnim i skończonym polu, prawdopodobieństwo zdarzenia $A \in \{B \cap \Omega : B \in \mathcal{B}(\mathbb{R}^2)\}$ określamy wzorem

$$\mathbb{P}(A) = \frac{\text{pole}(A)}{\text{pole}(\Omega)}. \tag{1.4}$$

1.4 Przykład: suma dwóch losowanych liczb

Przykład 1.1. Losujemy niezależnie i jednostajnie dwie liczby z przedziału $[0,1]$. Jakie jest prawdopodobieństwo, że ich suma jest większa od $1/2$?

Rozwiązanie. Przestrzenią stanów elementarnych jest kwadrat jednostkowy

$$\Omega = [0,1]^2 = \{(x,y) : x,y \in [0,1]\}.$$

Rozważamy zdarzenie

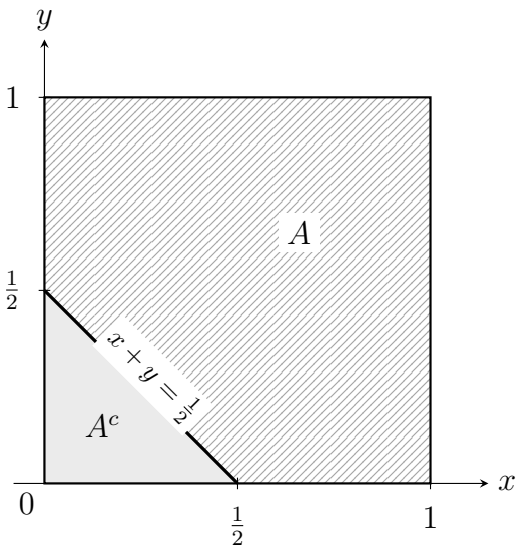
$$A = \{(x,y) \in [0,1]^2 : x+y > \tfrac{1}{2}\}.$$

Jego dopełnienie A^c jest trójkątem o wierzchołkach $(0,0)$, $(1/2,0)$ i $(0,1/2)$, przedstawionym na rysunku 1.1. Stąd

$$\text{pole}(A^c) = \frac{1}{2}\cdot\frac{1}{2}\cdot\frac{1}{2} = \frac{1}{8}, \qquad \text{pole}(\Omega) = 1.$$

Korzystając ze wzoru (1.4), otrzymujemy

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c) = 1 - \frac{\text{pole}(A^c)}{\text{pole}(\Omega)} = 1 - \frac{1}{8} = \boxed{\frac{7}{8}}. \tag{1.5}$$



Rysunek 1.1: Kwadrat $\Omega = [0,1]^2$ oraz zdarzenia $A = \{x+y > 1/2\}$ i $A^c = \{x+y \leqslant 1/2\}$.

Uwaga 1.2. Na tablicy zapisano $x+y \geqslant 1/2$. Odcinek $x+y = 1/2$ ma pole równe zero, więc zastąpienie znaku $>$ znakiem $\geqslant$ nie zmienia wyniku.

1.5 Własności prawdopodobieństwa

Twierdzenie 1.1. *Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną. Wówczas zachodzą następujące własności.*

1) Dla każdego $A \in \mathcal{F}$ zachodzi

$$0 \leqslant \mathbb{P}(A) \leqslant 1.$$

2) Zdarzenie niemożliwe i zdarzenie pewne mają prawdopodobieństwa

$$\mathbb{P}(\varnothing) = 0, \qquad \mathbb{P}(\Omega) = 1.$$

3) Dla każdego $A \in \mathcal{F}$ zachodzi

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A).$$

4) Jeżeli $A, B \in \mathcal{F}$ oraz $A \subseteq B$, to

$$\mathbb{P}(A) \leqslant \mathbb{P}(B).$$

5) Dla $A, B \in \mathcal{F}$ mamy

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \leqslant \mathbb{P}(A) + \mathbb{P}(B).$$

Ogólniej, dla dowolnych zdarzeń $A_1, A_2, \ldots \in \mathcal{F}$ zachodzi przeliczalna podaddytywność*:*

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) \leqslant \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

6) Jeżeli $A_1 \subseteq A_2 \subseteq \cdots$ jest rosnącym ciągiem zdarzeń, to

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} \mathbb{P}(A_n). \tag{1.6}$$

7) Jeżeli $A_1 \supseteq A_2 \supseteq \cdots$ jest malejącym ciągiem zdarzeń, to

$$\mathbb{P}\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} \mathbb{P}(A_n). \tag{1.7}$$

Dowód własności 6. Przyjmijmy $A_0 = \varnothing$ i zdefiniujmy

$$B_n = A_n \setminus A_{n-1}, \qquad n = 1, 2, \ldots.$$

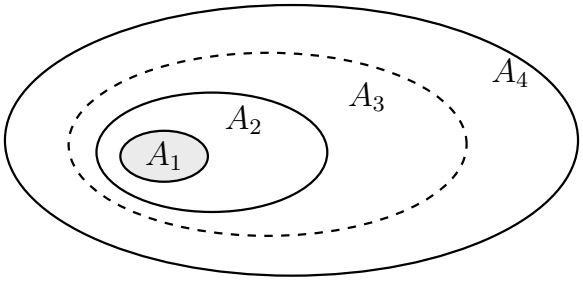
Zdarzenia B_n są parami rozłączne; ilustruje to rysunek 1.2. Ponadto dla każdego $N \geqslant 1$

$$\bigcup_{n=1}^{N} B_n = \bigcup_{n=1}^{N} A_n = A_N, \qquad \bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n.$$

Z przeliczalnej addytywności otrzymujemy

$$\begin{aligned}\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) &= \mathbb{P}\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(B_n) \\ &= \lim_{N\to\infty} \sum_{n=1}^{N} \mathbb{P}(B_n) = \lim_{N\to\infty} \mathbb{P}\left(\bigcup_{n=1}^{N} B_n\right) \\ &= \lim_{N\to\infty} \mathbb{P}(A_N).\end{aligned}$$

□



$A_1 \subseteq A_2 \subseteq A_3 \subseteq A_4 \subseteq \cdots$

Rysunek 1.2: Rosnący ciąg zdarzeń. Kolejne różnice $B_n = A_n \setminus A_{n-1}$ są parami rozłączne.

Dowód własności 7. Skoro $A_1 \supseteq A_2 \supseteq \cdots$, to $A_1^c \subseteq A_2^c \subseteq \cdots$. Korzystamy z prawa de Morgana oraz z udowodnionej własności 6:

$$\begin{aligned}\mathbb{P}\left(\bigcap_{n=1}^{\infty} A_n\right) &= 1 - \mathbb{P}\left(\left(\bigcap_{n=1}^{\infty} A_n\right)^c\right) \\ &= 1 - \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n^c\right) \\ &= 1 - \lim_{n\to\infty} \mathbb{P}(A_n^c) = \lim_{n\to\infty} \Big(1 - \mathbb{P}(A_n^c)\Big) \\ &= \lim_{n\to\infty} \mathbb{P}(A_n).\end{aligned}$$

□

Rozdział 2

Prawdopodobieństwo warunkowe

2.1 Definicja i podstawowe własności

Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną.

Definicja 2.1. Dla zdarzeń $A, B \in \mathcal{F}$ takich, że $\mathbb{P}(B) > 0$, *prawdopodobieństwo warunkowe zdarzenia A pod warunkiem B* definiujemy wzorem

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \tag{2.1}$$

Uwaga 2.1. Przy ustalonym $B \in \mathcal{F}$ o dodatnim prawdopodobieństwie wzór

$$\mathbb{P}_B(A) = \mathbb{P}(A \mid B), \qquad A \in \mathcal{F},$$

definiuje nowe prawdopodobieństwo na $(\Omega, \mathcal{F})$.

Fakt 2.1. *Niech $A, B \in \mathcal{F}$ oraz $\mathbb{P}(B) > 0$. Wówczas:*

1) jeśli $A \subseteq B$, to

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A)}{\mathbb{P}(B)};$$

2) jeśli $B \subseteq A$, to $\mathbb{P}(A \mid B) = 1$;

3) jeśli $A \cap B = \varnothing$, to $\mathbb{P}(A \mid B) = 0$; ogólniej, wystarczy warunek $\mathbb{P}(A \cap B) = 0$;

4) jeśli $C \in \mathcal{F}$ i $\mathbb{P}(B \cap C) > 0$, to

$$\mathbb{P}(A \mid B \cap C) = \frac{\mathbb{P}(A \cap B \mid C)}{\mathbb{P}(B \mid C)}. \tag{2.2}$$

Przykład 2.1 (Rodzina z dwojgiem dzieci)**.** Wybieramy rodzinę z dwojgiem dzieci. Jakie jest prawdopodobieństwo, że ma ona dwóch chłopców, jeśli:

a) starsze dziecko jest chłopcem;

b) w rodzinie jest co najmniej jeden chłopiec?

Zakładamy, że płcie dzieci są niezależne, a każda z dwóch płci ma prawdopodobieństwo 1/2.

Rozwiązanie. Kodujemy chłopca przez 0, a dziewczynkę przez 1. Pierwsza współrzędna odpowiada starszemu dziecku. Cztery stany elementarne

$$\Omega = \{(0,0),(0,1),(1,0),(1,1)\}$$

są jednakowo prawdopodobne. Przyjmujemy

$$\begin{aligned} A &= \{(0,0)\},\\ B_1 &= \{(0,0),(0,1)\},\\ B_2 &= \{(0,0),(0,1),(1,0)\}. \end{aligned}$$

Ponieważ $A \subseteq B_1$ i $A \subseteq B_2$, otrzymujemy

$$\mathbb{P}(A \mid B_1) = \frac{1/4}{1/2} = \frac{1}{2}, \qquad \mathbb{P}(A \mid B_2) = \frac{1/4}{3/4} = \frac{1}{3}.$$

2.2 Prawdopodobieństwo całkowite

Definicja 2.2. *Rozbiciem przestrzeni* Ω nazywamy rodzinę zbiorów $(B_n)_{n\in I}$, gdzie $I \subseteq \mathbb{N}$ jest zbiorem indeksów, taką, że:

1) $B_n \cap B_m = \varnothing$ dla $n, m \in I$, $n \neq m$;

2) $\bigcup_{n\in I} B_n = \Omega$.

Rozbicie może być skończone lub przeliczalne.

Twierdzenie 2.1 (O prawdopodobieństwie całkowitym)**.** *Niech* $(B_n)_{n\in I}$ *będzie rozbiciem* Ω *takim, że* $B_n \in \mathcal{F}$ *i* $\mathbb{P}(B_n) > 0$ *dla każdego* $n \in I$*. Wówczas dla dowolnego* $A \in \mathcal{F}$ *zachodzi*

$$\mathbb{P}(A) = \sum_{n\in I} \mathbb{P}(A \mid B_n)\mathbb{P}(B_n). \tag{2.3}$$

Dowód. Zdarzenia $A \cap B_n$ są parami rozłączne. Zatem

$$\begin{aligned} \mathbb{P}(A) = \mathbb{P}(A\cap\Omega) &= \mathbb{P}\left(A \cap \bigcup_{n\in I} B_n\right)\\ &= \mathbb{P}\left(\bigcup_{n\in I}(A\cap B_n)\right) = \sum_{n\in I}\mathbb{P}(A\cap B_n)\\ &= \sum_{n\in I}\mathbb{P}(A \mid B_n)\mathbb{P}(B_n). \end{aligned}$$

□

Przykład 2.2 (Zniszczenie celu)**.** Prawdopodobieństwo trafienia w cel wynosi 1/2, a wyniki kolejnych strzałów są niezależne. Prawdopodobieństwo zniszczenia celu przy dokładnie k celnych strzałach wynosi $1-(1/3)^k$. Jakie jest prawdopodobieństwo zniszczenia celu po oddaniu dziesięciu strzałów?

Rozwiązanie. Niech A oznacza zniszczenie celu, a B_i zdarzenie, że dokładnie i spośród dziesięciu strzałów jest celnych, gdzie $i = 0, 1, \ldots, 10$. Wówczas

$$\mathbb{P}(A \mid B_i) = 1 - \left(\frac{1}{3}\right)^i, \qquad \mathbb{P}(B_i) = \binom{10}{i}\left(\frac{1}{2}\right)^{10}.$$

Korzystając ze wzoru (2.3) i ze wzoru dwumianowego

$$(a+b)^n = \sum_{i=0}^{n} \binom{n}{i} a^i b^{n-i},$$

otrzymujemy

$$\begin{aligned}\mathbb{P}(A) &= \sum_{i=0}^{10} \left(1 - \left(\frac{1}{3}\right)^i\right)\binom{10}{i}\left(\frac{1}{2}\right)^{10} \\ &= \sum_{i=0}^{10} \binom{10}{i}\left(\frac{1}{2}\right)^{10} - \sum_{i=0}^{10} \binom{10}{i}\left(\frac{1}{6}\right)^i\left(\frac{1}{2}\right)^{10-i} \\ &= 1 - \left(\frac{1}{6}+\frac{1}{2}\right)^{10} = \boxed{1 - \left(\frac{2}{3}\right)^{10}}.\end{aligned}$$

Przykład 2.3 (Dwie urny)**.** Mamy dwie urny, każda zawiera sto kul. Jedna kula jest biała: trafia do pierwszej urny z prawdopodobieństwem 2/3, a do drugiej z prawdopodobieństwem 1/3. Pozostałe kule są czarne. Wykonujemy osiemdziesiąt losowań ze zwracaniem. Jak rozdzielić losowania między urny, aby zmaksymalizować prawdopodobieństwo wylosowania białej kuli co najmniej raz?

Rozwiązanie. Niech B_i oznacza zdarzenie, że biała kula znajduje się w i-tej urnie, a A zdarzenie, że zostanie wylosowana co najmniej raz. Wykonujemy k losowań z pierwszej urny i $m = 80-k$ z drugiej. Oznaczmy przez $q = 99/100$ prawdopodobieństwo wylosowania czarnej kuli z urny zawierającej białą kulę. Wówczas

$$\mathbb{P}(A \mid B_1) = 1 - q^k, \qquad \mathbb{P}(A \mid B_2) = 1 - q^{80-k}.$$

Ze wzoru (2.3) otrzymujemy

$$\mathbb{P}(A) = f(k) = \frac{2}{3}(1-q^k) + \frac{1}{3}(1-q^{80-k}), \qquad k \in \{0, 1, \ldots, 80\}. \tag{2.4}$$

Aby znaleźć maksimum, rozważamy najpierw zmienną rzeczywistą $x \in [0, 80]$. Liczymy

$$f'(x) = \frac{\ln q}{3}\left(q^{80-x} - 2q^x\right).$$

Warunek $f'(x) = 0$ jest równoważny

$$q^{80-2x} = 2, \qquad x = \frac{1}{2}\left(80 - \frac{\ln 2}{\ln q}\right) \approx 74{,}484.$$

Ponieważ

$$f''(x) = -\frac{(\ln q)^2}{3}\left(q^{80-x} + 2q^x\right) < 0,$$

jest to jedyny punkt maksimum. Dla całkowitej liczby losowań porównujemy dwóch kandydatów:

$$f(74) \approx 0{,}3692799222, \qquad f(75) \approx 0{,}3692788890.$$

Najlepiej wykonać *74 losowania z pierwszej urny i 6 z drugiej*. Oba powyższe prawdopodobieństwa po zaokrągleniu do czterech miejsc po przecinku wynoszą 0,3693.

2.3 Wzór Bayesa

Twierdzenie 2.2 (Wzór Bayesa)**.** *Niech $(B_n)_{n\in I}$ będzie rozbiciem Ω takim, że $B_n \in \mathcal{F}$ i $\mathbb{P}(B_n) > 0$ dla każdego $n \in I$. Jeżeli $A \in \mathcal{F}$ i $\mathbb{P}(A) > 0$, to dla każdego $n \in I$*

$$\mathbb{P}(B_n \mid A) = \frac{\mathbb{P}(A \mid B_n)\mathbb{P}(B_n)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B_n)\mathbb{P}(B_n)}{\sum_{k\in I} \mathbb{P}(A \mid B_k)\mathbb{P}(B_k)}. \tag{2.5}$$

Przykład 2.4 (ZONK)**.** Za jedną z trzech bramek znajduje się nagroda, a za pozostałymi dwoma zonki. Każda bramka zawiera nagrodę z prawdopodobieństwem 1/3. Wybieramy pierwszą bramkę. Filip Chajzer zna położenie nagrody i otwiera jedną z pozostałych bramek, zawsze pokazując zonka. Jeżeli może otworzyć obie, wybiera każdą z prawdopodobieństwem 1/2. Chajzer otworzył trzecią bramkę. Jakie jest prawdopodobieństwo, że nagroda znajduje się w drugiej bramce? Czy warto zmienić wybór?

Rozwiązanie. Przyjmujemy oznaczenia

$$A = \{\text{Chajzer otwiera trzecią bramkę}\}, \qquad B_i = \{\text{nagroda jest w } i\text{-tej bramce}\},$$

gdzie $i = 1, 2, 3$. Zdarzenia B_1, B_2, B_3 tworzą rozbicie Ω, a $\mathbb{P}(B_i) = 1/3$ dla każdego i. Jeśli nagroda znajduje się w pierwszej bramce, prowadzący ma wybór między drugą a trzecią. Jeśli znajduje się w drugiej, musi otworzyć trzecią; jeśli w trzeciej, musi otworzyć drugą. Stąd

$$\mathbb{P}(A \mid B_1) = \frac{1}{2}, \qquad \mathbb{P}(A \mid B_2) = 1, \qquad \mathbb{P}(A \mid B_3) = 0.$$

Ze wzoru na prawdopodobieństwo całkowite (2.3) mamy

$$\mathbb{P}(A) = \frac{1}{2}\cdot\frac{1}{3} + 1\cdot\frac{1}{3} + 0\cdot\frac{1}{3} = \frac{1}{2}.$$

Zatem wzór Bayesa (2.5) daje

$$\mathbb{P}(B_2 \mid A) = \frac{\mathbb{P}(A \mid B_2)\mathbb{P}(B_2)}{\mathbb{P}(A)} = \frac{1\cdot(1/3)}{1/2} = \boxed{\frac{2}{3}}. \tag{2.6}$$

Natomiast $\mathbb{P}(B_1 \mid A) = 1/3$. Warto więc zmienić wybór z pierwszej bramki na drugą: prawdopodobieństwo wygranej wzrasta z 1/3 do 2/3.

Przykład 2.5 (Moneta z dwoma orłami)**.** Mamy sto monet: dziewięćdziesiąt dziewięć uczciwych i jedną z orłem na obu stronach. Wybieramy monetę losowo i rzucamy nią dziesięć razy. Za każdym razem wypada orzeł. Jakie jest prawdopodobieństwo, że wybraliśmy monetę z dwoma orłami?

Rozwiązanie. Niech A oznacza dziesięć orłów, B_1 wybór uczciwej monety, a B_2 wybór monety z dwoma orłami. Wówczas

$$\mathbb{P}(B_1) = \frac{99}{100}, \qquad \mathbb{P}(B_2) = \frac{1}{100},$$
$$\mathbb{P}(A \mid B_1) = \left(\frac{1}{2}\right)^{10}, \qquad \mathbb{P}(A \mid B_2) = 1.$$

Prawdopodobieństwo dziesięciu orłów wynosi

$$\mathbb{P}(A) = \left(\frac{1}{2}\right)^{10} \frac{99}{100} + \frac{1}{100}.$$

Ze wzoru Bayesa (2.5) otrzymujemy

$$\mathbb{P}(B_2 \mid A) = \frac{1/100}{(1/2)^{10} \cdot 99/100 + 1/100} = \frac{1024}{1123} \approx \boxed{0{,}9118}. \tag{2.7}$$

Rozdział 3

Niezależność

3.1 Niezależność dwóch zdarzeń

Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną.

Definicja 3.1. Zdarzenia $A, B \in \mathcal{F}$ są *niezależne*, jeżeli

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B). \tag{3.1}$$

Uwaga 3.1. Jeżeli $\mathbb{P}(A) > 0$ i zdarzenia A, B są niezależne, to

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(A)} = \mathbb{P}(B).$$

Przykład 3.1 (Dwa rzuty kostką)**.** Rzucamy dwukrotnie uczciwą kostką; wyniki rzutów są niezależne. Niech A oznacza wyrzucenie szóstki w pierwszym rzucie, B wyrzucenie jedynki w drugim rzucie, a C uzyskanie parzystych wyników w obu rzutach. Sprawdźmy niezależność tych zdarzeń.

Rozwiązanie. Przyjmujemy $\Omega = \{1, 2, \ldots, 6\}^2$ z jednakowo prawdopodobnymi wynikami. Mamy

$$\mathbb{P}(A) = \mathbb{P}(B) = \frac{1}{6}, \qquad \mathbb{P}(C) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

Ponadto

$$\begin{aligned}
\mathbb{P}(A \cap B) &= \frac{1}{36} = \mathbb{P}(A)\mathbb{P}(B), \\
\mathbb{P}(A \cap C) &= \frac{1}{6} \cdot \frac{1}{2} = \frac{1}{12} \neq \frac{1}{24} = \mathbb{P}(A)\mathbb{P}(C), \\
\mathbb{P}(B \cap C) &= 0 \neq \frac{1}{24} = \mathbb{P}(B)\mathbb{P}(C).
\end{aligned}$$

Zdarzenia A i B są niezależne, natomiast pary A, C oraz B, C nie są niezależne.

Przykład 3.2 (Rzuty monetą)**.** Rzucamy $n \geqslant 2$ razy uczciwą monetą, niezależnie w kolejnych próbach. Niech A oznacza, że wypadła co najwyżej jedna reszka, a B, że nie wypadły ani same orły, ani same reszki. Dla jakich n zdarzenia A i B są niezależne?

Rozwiązanie. Wszystkie 2^n ciągów wyników są jednakowo prawdopodobne. Zdarzenie A obejmuje ciąg samych orłów oraz n ciągów z jedną reszką, więc

$$\mathbb{P}(A) = \frac{1+n}{2^n}, \qquad \mathbb{P}(B) = 1 - \mathbb{P}(B^c) = 1 - \frac{2}{2^n}.$$

Dla $n \geqslant 2$ zdarzenie $A \cap B$ oznacza dokładnie jedną reszkę, stąd $\mathbb{P}(A \cap B) = n/2^n$. Warunek niezależności jest równoważny

$$\begin{aligned} \frac{n}{2^n} &= \frac{n+1}{2^n}\left(1 - \frac{2}{2^n}\right), \\ n2^n &= (n+1)(2^n - 2), \\ 2(n+1) &= 2^n, \qquad \text{czyli} \qquad n+1 = 2^{n-1}. \end{aligned}$$

Równość zachodzi dla $n = 3$. Dla $n = 2$ nie jest spełniona, a dla $n \geqslant 4$ mamy $2^{n-1} > n+1$ (nierówność utrzymuje się indukcyjnie). Zatem *zdarzenia są niezależne dokładnie dla* $n = 3$.

3.2 Niezależność rodzin zdarzeń

Definicja 3.2. Rodzina zdarzeń $(A_t)_{t\in T}$, gdzie T jest dowolnym zbiorem indeksów, jest *niezależna*, jeżeli dla każdego $m \geqslant 1$ i każdych parami różnych $t_1, \ldots, t_m \in T$ zachodzi

$$\mathbb{P}\left(\bigcap_{i=1}^{m} A_{t_i}\right) = \prod_{i=1}^{m} \mathbb{P}(A_{t_i}). \tag{3.2}$$

W szczególności zdarzenia $A_1, \ldots, A_n$ są niezależne, gdy dla każdego $m \in \{2, \ldots, n\}$ i każdych indeksów $1 \leqslant t_1 < \cdots < t_m \leqslant n$ spełniony jest wzór (3.2).

Definicja 3.3. Zdarzenia $A_1, \ldots, A_n$ są *parami niezależne*, jeżeli

$$\mathbb{P}(A_i \cap A_j) = \mathbb{P}(A_i)\mathbb{P}(A_j) \qquad \text{dla wszystkich } i \neq j.$$

Definicja 3.4. Dwie rodziny zdarzeń $\mathcal{A}, \mathcal{B} \subseteq \mathcal{F}$ są *niezależne*, jeżeli dla każdych $A \in \mathcal{A}$ oraz $B \in \mathcal{B}$ zachodzi

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Definicja 3.5. Rodziny zdarzeń $(\mathcal{A}_t)_{t\in T}$, gdzie $\mathcal{A}_t \subseteq \mathcal{F}$, są *niezależne*, jeżeli dla każdego $m \geqslant 1$, każdych parami różnych $t_1, \ldots, t_m \in T$ oraz dowolnych zdarzeń $A_{t_i} \in \mathcal{A}_{t_i}$, $i = 1, \ldots, m$, mamy

$$\mathbb{P}(A_{t_1} \cap \cdots \cap A_{t_m}) = \mathbb{P}(A_{t_1}) \cdots \mathbb{P}(A_{t_m}).$$

Przykład 3.3 (Niezależność parami nie wystarcza)**.** Losujemy niezależnie i jednostajnie dwie liczby x, y z odcinka $[0,1]$. Przyjmujemy model geometryczny na $\Omega = [0,1]^2$ i zdarzenia

$$\begin{aligned} A &= \{(x,y) \in \Omega : x \geqslant \tfrac{1}{2}\}, \\ B &= \{(x,y) \in \Omega : y \geqslant \tfrac{1}{2}\}, \\ C &= \{(x,y) \in \Omega : \min\{x,y\} > \tfrac{1}{2} \text{ lub } \max\{x,y\} \leqslant \tfrac{1}{2}\}. \end{aligned}$$

Czy zdarzenia A, B, C są niezależne?

Rozwiązanie. Zdarzenie C zajmuje dwa kwadraty leżące po przekątnej kwadratu jednostkowego, jak na rysunku 3.1. Prawdopodobieństwa obliczamy jako pola odpowiednich obszarów:

$$\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}.$$

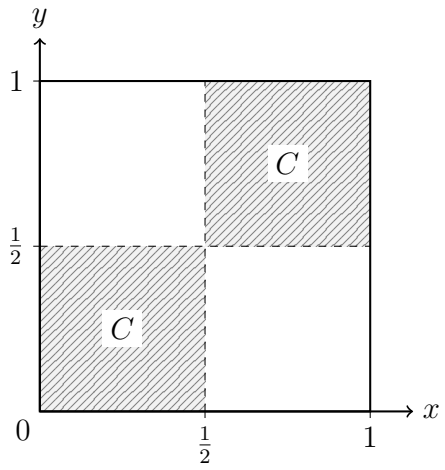
Każde z przecięć dwóch zdarzeń ma pole $1/4$, zatem

$$\begin{aligned}
\mathbb{P}(A \cap B) &= \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(B), \\
\mathbb{P}(A \cap C) &= \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(C), \\
\mathbb{P}(B \cap C) &= \frac{1}{4} = \mathbb{P}(B)\mathbb{P}(C).
\end{aligned}$$

Jednak

$$\mathbb{P}(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

Zdarzenia są więc parami niezależne, lecz rodzina A, B, C nie jest niezależna. Brzegi obszarów mają pole zero i nie wpływają na powyższe rachunki.



Rysunek 3.1: Zdarzenie C obejmuje dwa zakreskowane kwadraty. Zdarzeniu A odpowiada prawa połowa, a B górna połowa Ω.

3.3 Własności niezależności

Fakt 3.1. *Dla zdarzeń $A, B \in \mathcal{F}$ zachodzą następujące własności.*

1) Jeżeli $\mathbb{P}(B) > 0$ oraz A, B są niezależne, to $\mathbb{P}(A \mid B) = \mathbb{P}(A)$.

2) Jeżeli A, B są niezależne, to niezależne są również pary A, B^c, A^c, B oraz A^c, B^c.

3) Jeżeli $\mathbb{P}(A) = 0$ lub $\mathbb{P}(A) = 1$, to A jest niezależne od każdego zdarzenia $B \in \mathcal{F}$.

4) Jeżeli A jest niezależne od samego siebie, to $\mathbb{P}(A) = 0$ lub $\mathbb{P}(A) = 1$.

3.4 Schemat Bernoulliego

Definicja 3.6. *Schematem Bernoulliego* nazywamy ciąg niezależnych powtórzeń tego samego doświadczenia, w którym możliwe są tylko dwa wyniki: *sukces* z prawdopodobieństwem p oraz *porażka* z prawdopodobieństwem $q = 1 - p$.

Fakt 3.2. *W schemacie Bernoulliego prawdopodobieństwo uzyskania dokładnie k sukcesów w n próbach wynosi*

$$P_k = \binom{n}{k} p^k (1-p)^{n-k}, \qquad k = 0, 1, \ldots, n. \tag{3.3}$$

Dowód. Przyjmujemy $\Omega = \{0,1\}^n$, gdzie 1 oznacza sukces, a 0 porażkę. Dla $a = (a_1, \ldots, a_n) \in \Omega$ niezależność prób daje

$$\mathbb{P}(\{a\}) = p^{a_1 + \cdots + a_n} (1-p)^{n - (a_1 + \cdots + a_n)}.$$

Zdarzenie uzyskania dokładnie k sukcesów ma postać

$$A_k = \{(a_1, \ldots, a_n) \in \Omega : a_1 + \cdots + a_n = k\}.$$

Liczba takich ciągów wynosi $|A_k| = \binom{n}{k}$, a każdy z nich ma prawdopodobieństwo $p^k(1-p)^{n-k}$. Zatem

$$\mathbb{P}(A_k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

□

3.5 Granice ciągów zdarzeń

Definicja 3.7. Dla ciągu zdarzeń $(A_n)_{n \geqslant 1}$ definiujemy *granicę górną* oraz *granicę dolną* wzorami

$$\limsup_{n\to\infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k, \tag{3.4}$$

$$\liminf_{n\to\infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k. \tag{3.5}$$

Fakt 3.3.

1) $\omega \in \limsup_{n\to\infty} A_n$ *wtedy i tylko wtedy, gdy* ω *należy do nieskończenie wielu zdarzeń* A_n.

2) $\omega \in \liminf_{n\to\infty} A_n$ *wtedy i tylko wtedy, gdy* ω *należy do wszystkich* A_n *od pewnego indeksu, czyli do prawie wszystkich zdarzeń tego ciągu.*

3) $\liminf\limits_{n\to\infty} A_n \subseteq \limsup\limits_{n\to\infty} A_n$.

3.6 Lemat Borela–Cantellego

Lemat 3.1 (Borela–Cantellego)**.** *Niech $(A_n)_{n\geqslant 1}$ będzie ciągiem zdarzeń.*

1) Jeśli $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$*, to*

$$\mathbb{P}\Big(\limsup_{n\to\infty} A_n\Big) = 0.$$

2) Jeśli zdarzenia A_n są niezależne i $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$*, to*

$$\mathbb{P}\Big(\limsup_{n\to\infty} A_n\Big) = 1.$$

Dowód punktu 1. Oznaczmy $B_n = \bigcup_{k=n}^{\infty} A_k$. Ciąg (B_n) jest malejący, a jego przecięcie jest równe $\limsup_{n\to\infty} A_n$. Z ciągłości prawdopodobieństwa dla ciągu malejącego (1.7) oraz podaddytywności otrzymujemy

$$\begin{aligned} 0 \leqslant \mathbb{P}\Big(\limsup_{n\to\infty} A_n\Big) &= \lim_{n\to\infty} \mathbb{P}(B_n) \\ &= \lim_{n\to\infty} \mathbb{P}\Big(\bigcup_{k=n}^{\infty} A_k\Big) \\ &\leqslant \lim_{n\to\infty} \sum_{k=n}^{\infty} \mathbb{P}(A_k) = 0. \end{aligned}$$

Ostatnia granica jest zerowa, ponieważ są to ogony szeregu zbieżnego. □

Dowód punktu 2. Ponownie korzystamy z ciągłości prawdopodobieństwa oraz z prawa de Morgana:

$$\begin{aligned} \mathbb{P}\Big(\limsup_{n\to\infty} A_n\Big) &= \lim_{n\to\infty} \mathbb{P}\Big(\bigcup_{k=n}^{\infty} A_k\Big) \\ &= 1 - \lim_{n\to\infty} \mathbb{P}\Big(\bigcap_{k=n}^{\infty} A_k^c\Big) \\ &= 1 - \lim_{n\to\infty} \lim_{N\to\infty} \mathbb{P}\Big(\bigcap_{k=n}^{N} A_k^c\Big) \\ &= 1 - \lim_{n\to\infty} \lim_{N\to\infty} \prod_{k=n}^{N} \big(1 - \mathbb{P}(A_k)\big). \end{aligned}$$

Ostatnia równość wynika z niezależności zdarzeń i ich dopełnień. Z nierówności $1 + x \leqslant e^x$, zastosowanej do $x = -\mathbb{P}(A_k)$, dostajemy

$$0 \leqslant \prod_{k=n}^{N} \big(1 - \mathbb{P}(A_k)\big) \leqslant \prod_{k=n}^{N} e^{-\mathbb{P}(A_k)} = \exp\Big(-\sum_{k=n}^{N} \mathbb{P}(A_k)\Big).$$

Dla każdego ustalonego n suma w wykładniku dąży do $+\infty$, ponieważ $\sum_{k=1}^{\infty} \mathbb{P}(A_k) = \infty$. Stąd granica iloczynu przy $N \to \infty$ wynosi zero, a więc

$$1 \geqslant \mathbb{P}\Big(\limsup_{n\to\infty} A_n\Big) \geqslant 1 - \lim_{n\to\infty} \exp\Big(-\sum_{k=n}^{\infty} \mathbb{P}(A_k)\Big) = 1.$$

To kończy dowód. □

Przykład 3.4 (Nieskończenie wiele wystąpień układu ORRO)**.** Rzucamy nieskończenie wiele razy uczciwą monetą, niezależnie w kolejnych próbach. Jakie jest prawdopodobieństwo, że układ ORRO, czyli orzeł, reszka, reszka, orzeł, wystąpi nieskończenie wiele razy?

Rozwiązanie. Niech

$$A_n = \{\text{układ ORRO występuje w rzutach } n, n+1, n+2, n+3\}.$$

Wówczas

$$\mathbb{P}(A_n) = \left(\frac{1}{2}\right)^4 = \frac{1}{16}, \qquad \sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty.$$

Nie możemy od razu zastosować drugiej części lematu Borela–Cantellego, ponieważ zdarzenia A_n nie są niezależne: bloki kolejnych rzutów nakładają się. Wybierzmy zatem

$$B_n = A_{4n}, \qquad n \geqslant 1.$$

Zdarzenia B_n dotyczą rozłącznych bloków rzutów, więc są niezależne, a ponadto

$$\mathbb{P}(B_n) = \frac{1}{16}, \qquad \sum_{n=1}^{\infty} \mathbb{P}(B_n) = \infty.$$

Z lematu 3.1 otrzymujemy

$$\mathbb{P}\Big(\limsup_{n\to\infty} B_n\Big) = 1.$$

Ponieważ

$$\limsup_{n\to\infty} B_n \subseteq \limsup_{n\to\infty} A_n,$$

mamy również

$$\mathbb{P}\Big(\limsup_{n\to\infty} A_n\Big) = 1.$$

Zatem układ ORRO występuje nieskończenie wiele razy z prawdopodobieństwem 1.

Rozdział 4

Zmienne losowe

4.1 Definicja i mierzalność

Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną.

Definicja 4.1. *Zmienną losową o wartościach w* $\mathbb{R}$ na przestrzeni $(\Omega, \mathcal{F}, \mathbb{P})$ nazywamy funkcję $X\colon \Omega \to \mathbb{R}$ taką, że

$$X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\} \in \mathcal{F} \qquad \text{dla każdego } A \in \mathcal{B}(\mathbb{R}).$$

Tutaj $\mathcal{B}(\mathbb{R})$ oznacza σ-ciało zbiorów borelowskich prostej.

Uwaga 4.1. Analogicznie definiujemy zmienną losową $X\colon \Omega \to \mathbb{R}^d$, wymagając, aby $X^{-1}(A) \in \mathcal{F}$ dla każdego $A \in \mathcal{B}(\mathbb{R}^d)$. Taką zmienną nazywamy *wektorem losowym*.

Uwaga 4.2. Zmienna losowa jest funkcją mierzalną.

Uwaga 4.3. Aby funkcja $X\colon \Omega \to \mathbb{R}$ była zmienną losową, wystarczy, żeby

$$\{\omega \in \Omega : X(\omega) > a\} \in \mathcal{F} \qquad \text{dla każdego } a \in \mathbb{R}.$$

Uwaga 4.4 (Zapis prawdopodobieństw)**.** Dla zbioru borelowskiego $A \subseteq \mathbb{R}$ stosujemy skrót

$$\mathbb{P}(X \in A) = \mathbb{P}\Big(\{\omega \in \Omega : X(\omega) \in A\}\Big).$$

Uwaga 4.5 (Mierzalność funkcji)**.** Funkcja $f\colon (E, \mathcal{E}) \to (S, \mathcal{S})$ jest *mierzalna*, jeżeli

$$f^{-1}(A) \in \mathcal{E} \qquad \text{dla każdego } A \in \mathcal{S}.$$

Fakt 4.1. *Jeżeli* $X\colon \Omega \to \mathbb{R}^d$ *jest wektorem losowym, a funkcja* $\varphi\colon \mathbb{R}^d \to \mathbb{R}^m$ *jest borelowska, to*

$$\varphi(X) = \varphi \circ X\colon \Omega \to \mathbb{R}^m$$

jest wektorem losowym (dla $m = 1$ *— zmienną losową rzeczywistą).*

Uwaga 4.6. Funkcja $\varphi\colon \mathbb{R}^d \to \mathbb{R}^m$ jest *borelowska*, jeżeli

$$\varphi^{-1}(A) \in \mathcal{B}(\mathbb{R}^d) \qquad \text{dla każdego } A \in \mathcal{B}(\mathbb{R}^m).$$

4.2 σ-ciało generowane przez zmienną losową

Definicja 4.2. Niech $X\colon \Omega \to \mathbb{R}$ będzie zmienną losową. Najmniejsze σ-ciało $\mathcal{G} \subseteq \mathcal{F}$, względem którego X jest mierzalna, nazywamy *σ-ciałem generowanym przez X* i oznaczamy przez $\sigma(X)$.

Fakt 4.2. *Dla zmiennej losowej $X\colon \Omega \to \mathbb{R}$ mamy*

$$\sigma(X) = \{X^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\}.$$

Przykład 4.1 (Zmienna przyjmująca dwie wartości)**.** Niech $A \in \mathcal{F}$ oraz $a, b \in \mathbb{R}$, $a \neq b$. Rozważmy zmienną losową

$$X(\omega) = a\mathbf{1}_A(\omega) + b\mathbf{1}_{A^c}(\omega), \qquad \omega \in \Omega,$$

gdzie $\mathbf{1}_A$ jest funkcją charakterystyczną zbioru A. Dla $B \in \mathcal{B}(\mathbb{R})$ otrzymujemy

$$X^{-1}(B) = \begin{cases} \varnothing, & a \notin B,\ b \notin B, \\ A, & a \in B,\ b \notin B, \\ A^c, & a \notin B,\ b \in B, \\ \Omega, & a \in B,\ b \in B. \end{cases}$$

Zatem

$$\sigma(X) = \{\varnothing, A, A^c, \Omega\}.$$

4.3 Niezależność zmiennych losowych

Definicja 4.3. Zmienne losowe $X, Y\colon \Omega \to \mathbb{R}$ są *niezależne*, jeżeli dla każdych $A, B \in \mathcal{B}(\mathbb{R})$ zachodzi

$$\mathbb{P}(X \in A,\, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B).$$

Równoważnie: σ-ciała $\sigma(X)$ i $\sigma(Y)$ są niezależne.

Definicja 4.4. Zmienne losowe $X_1, \ldots, X_n$ są *niezależne*, jeżeli σ-ciała $\sigma(X_1)$, …, $\sigma(X_n)$ są niezależne. Ogólniej, dla dowolnego zbioru indeksów T rodzina zmiennych losowych $(X_t)_{t\in T}$ jest *niezależna*, jeżeli rodzina $\big(\sigma(X_t)\big)_{t\in T}$ jest niezależna.

Przykład 4.2 (Niezależne indykatory)**.** Rozważmy przestrzeń probabilistyczną

$$(\Omega, \mathcal{F}, \mathbb{P}) = \Big([0,1], \mathcal{B}([0,1]), \lambda\Big),$$

gdzie λ oznacza miarę Lebesgue'a na odcinku $[0,1]$. Niech

$$A = \left[0, \frac{1}{2}\right), \qquad B = \left[0, \frac{1}{4}\right) \cup \left[\frac{1}{2}, \frac{3}{4}\right), \qquad X = \mathbf{1}_A, \quad Y = \mathbf{1}_B.$$

Wówczas

$$\sigma(X) = \{\varnothing, A, A^c, \Omega\}, \qquad \sigma(Y) = \{\varnothing, B, B^c, \Omega\}.$$

Ponadto

$$\mathbb{P}(A \cap B) = \lambda\left(\left[0, \frac{1}{4}\right)\right) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A)\mathbb{P}(B).$$

Zdarzenia A, B są niezależne, a z własności niezależności (fakt 3.1) to samo dotyczy ich dopełnień. Zatem σ-ciała $\sigma(X)$ i $\sigma(Y)$ są niezależne, czyli zmienne losowe X, Y są niezależne.

Przykład 4.3 (Funkcje Rademachera)**.** Na tej samej przestrzeni probabilistycznej funkcje

$$X_n(x) = \operatorname{sgn}\Big(\sin(2^n \pi x)\Big), \qquad x \in [0,1], \quad n = 1, 2, \ldots,$$

tworzą rodzinę niezależnych zmiennych losowych. Zera sinusów występują w punktach dyadycznych, w tym na końcach odcinka; zbiór tych punktów ma miarę zero, więc wartości funkcji w tych punktach nie wpływają na niezależność.

Fakt 4.3. *Zmienna losowa $X\colon \Omega \to \mathbb{R}$ jest niezależna od samej siebie wtedy i tylko wtedy, gdy istnieje $c \in \mathbb{R}$ takie, że*

$$\mathbb{P}(X = c) = 1.$$

4.4 Układy π i λ

Definicja 4.5. Rodzinę zbiorów $\mathcal{P} \subseteq 2^\Omega$ nazywamy *π-układem*, jeżeli

$$A \cap B \in \mathcal{P} \qquad \text{dla wszystkich } A, B \in \mathcal{P}.$$

Przykład 4.4. Rodzina

$$\mathcal{P} = \{[a, b) : a, b \in \mathbb{R}\}$$

jest π-układem na $\mathbb{R}$. Przyjmujemy przy tym $[a, b) = \varnothing$ dla $a \geqslant b$.

Definicja 4.6. Rodzinę zbiorów $\mathcal{L} \subseteq 2^\Omega$ nazywamy *λ-układem*, jeżeli spełnia następujące warunki:

1) $\Omega \in \mathcal{L}$.
2) Jeżeli $A, B \in \mathcal{L}$ i $A \subseteq B$, to $B \setminus A \in \mathcal{L}$.
3) Jeżeli $A_1, A_2, \ldots \in \mathcal{L}$ oraz $A_n \subseteq A_{n+1}$ dla każdego $n \geqslant 1$, to

$$\bigcup_{n=1}^{\infty} A_n \in \mathcal{L}.$$

Fakt 4.4. *Jeżeli rodzina $\mathcal{F}$ jest jednocześnie π-układem i λ-układem, to jest σ-ciałem.*

Twierdzenie 4.1 (O układach π i λ)**.** *Jeżeli λ-układ $\mathcal{L}$ zawiera π-układ $\mathcal{P}$, to*

$$\sigma(\mathcal{P}) \subseteq \mathcal{L}.$$

4.4.1 Sposób stosowania twierdzenia

Chcąc udowodnić pewną własność $(*)$ dla każdego $A \in \mathcal{F}$, możemy postępować następująco:

1) Znajdujemy π-układ $\mathcal{P}$ taki, że $\sigma(\mathcal{P}) = \mathcal{F}$, i sprawdzamy własność $(*)$ dla każdego zbioru z $\mathcal{P}$.
2) Definiujemy rodzinę

$$\mathcal{L} = \{A \in \mathcal{F} : \text{własność } (*) \text{ zachodzi dla } A\}.$$

3) Wykazujemy, że $\mathcal{L}$ jest λ-układem.

4) Ponieważ $\mathcal{P} \subseteq \mathcal{L}$, z twierdzenia 4.1 otrzymujemy

$$\mathcal{F} = \sigma(\mathcal{P}) \subseteq \mathcal{L}.$$

Własność $(*)$ zachodzi więc dla każdego $A \in \mathcal{F}$.

4.5 Funkcje niezależnych zmiennych losowych

Twierdzenie 4.2. *Niech $X_1, \ldots, X_{n+m}$ będą niezależnymi zmiennymi losowymi, gdzie $n, m \geqslant 1$. Wówczas dla dowolnych zbiorów borelowskich $C \in \mathcal{B}(\mathbb{R}^n)$ i $D \in \mathcal{B}(\mathbb{R}^m)$ zdarzenia*

$$\{(X_1, \ldots, X_n) \in C\}, \qquad \{(X_{n+1}, \ldots, X_{n+m}) \in D\}$$

są niezależne. W szczególności, jeżeli funkcje

$$f\colon \mathbb{R}^n \to \mathbb{R}, \qquad g\colon \mathbb{R}^m \to \mathbb{R}$$

są borelowskie, to zmienne losowe

$$f(X_1, \ldots, X_n), \qquad g(X_{n+1}, \ldots, X_{n+m})$$

są niezależne.

Uwaga 4.7 (Więcej bloków)**.** Ogólniej, niech $X_1, \ldots, X_n$ będą niezależne oraz

$$0 = n_0 < n_1 < \cdots < n_k = n.$$

Jeżeli dla $i = 1, \ldots, k$ funkcje $f_i\colon \mathbb{R}^{n_i - n_{i-1}} \to \mathbb{R}$ są borelowskie, to zmienne

$$f_1(X_1, \ldots, X_{n_1}), \quad f_2(X_{n_1+1}, \ldots, X_{n_2}), \quad \ldots, \quad f_k(X_{n_{k-1}+1}, \ldots, X_n)$$

są niezależne.

Przykład 4.5. Jeżeli X_1, X_2, X_3 są niezależne, to $\sin(X_1 + X_2)$ i e^{X_3} są niezależne. Podobnie z niezależności X_1, X_2, X_3, X_4 wynika niezależność zmiennych $X_1 + X_2$ oraz $X_3 - X_4$.

Uwaga 4.8. Twierdzenie dotyczy funkcji oddzielnych bloków zmiennych. Z samej niezależności X_1 i X_2 nie można wnioskować, że zmienne $X_1 + X_2$ oraz $X_1 - X_2$ są niezależne.

Szkic dowodu twierdzenia 4.2. Oznaczmy

$$X = (X_1, \ldots, X_n), \qquad Y = (X_{n+1}, \ldots, X_{n+m}).$$

Chcemy wykazać, że

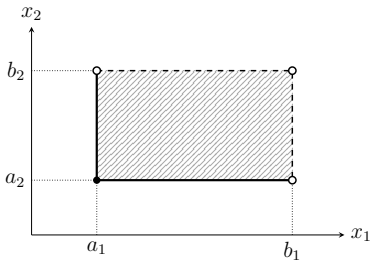
$$\mathbb{P}(X \in C, Y \in D) = \mathbb{P}(X \in C)\mathbb{P}(Y \in D) \tag{4.1}$$

dla wszystkich $C \in \mathcal{B}(\mathbb{R}^n)$ oraz $D \in \mathcal{B}(\mathbb{R}^m)$.

Dla $d \geqslant 1$ rozważmy rodzinę prostokątów

$$\mathcal{A}^d = \left\{ \prod_{i=1}^{d} [a_i, b_i) : a_i, b_i \in \mathbb{R},\ a_i \leqslant b_i \right\}.$$

Jest to π-układ i $\sigma(\mathcal{A}^d) = \mathcal{B}(\mathbb{R}^d)$. Przypadek $d = 2$ przedstawia rysunek 4.1.



Rysunek 4.1: Prostokąt $[a_1, b_1) \times [a_2, b_2)$. Dolne końce obu przedziałów są włączone, górne wyłączone.

Krok 1. Ustalmy $D \in \mathcal{A}^m$ i zdefiniujmy

$$\mathcal{L}_1 = \{C \in \mathcal{B}(\mathbb{R}^n) : \text{równość (4.1) zachodzi dla } C, D\}.$$

Rodzina $\mathcal{L}_1$ jest λ-układem: zawiera $\mathbb{R}^n$, jest zamknięta na różnice zbiorów zagnieżdżonych oraz na sumy ciągów rosnących. Wynika to odpowiednio z normalizacji, addytywności i ciągłości prawdopodobieństwa.

Jeżeli również $C \in \mathcal{A}^n$, to możemy zapisać

$$C = \prod_{i=1}^{n} [a_i, b_i), \qquad D = \prod_{i=n+1}^{n+m} [a_i, b_i).$$

Z niezależności wszystkich zmiennych otrzymujemy

$$\begin{aligned}
\mathbb{P}(X \in C,\, Y \in D) &= \mathbb{P}\left(\bigcap_{i=1}^{n+m} \{X_i \in [a_i, b_i)\} \right) \\
&= \prod_{i=1}^{n+m} \mathbb{P}(X_i \in [a_i, b_i)) \\
&= \left(\prod_{i=1}^{n} \mathbb{P}(X_i \in [a_i, b_i)) \right) \left(\prod_{i=n+1}^{n+m} \mathbb{P}(X_i \in [a_i, b_i)) \right) \\
&= \mathbb{P}(X \in C)\mathbb{P}(Y \in D).
\end{aligned}$$

Zatem $\mathcal{A}^n \subseteq \mathcal{L}_1$. Na mocy twierdzenia o układach π i λ (twierdzenie 4.1)

$$\mathcal{B}(\mathbb{R}^n) = \sigma(\mathcal{A}^n) \subseteq \mathcal{L}_1.$$

Równość (4.1) zachodzi więc dla każdego $C \in \mathcal{B}(\mathbb{R}^n)$ i ustalonego $D \in \mathcal{A}^m$.

Krok 2. Ustalmy teraz dowolny $C \in \mathcal{B}(\mathbb{R}^n)$ i połóżmy

$$\mathcal{L}_2 = \{D \in \mathcal{B}(\mathbb{R}^m) : \text{równość (4.1) zachodzi dla } C, D\}.$$

Rodzina $\mathcal{L}_2$ również jest λ-układem. Z poprzedniego kroku wynika $\mathcal{A}^m \subseteq \mathcal{L}_2$. Ponownie stosując twierdzenie 4.1, dostajemy

$$\mathcal{B}(\mathbb{R}^m) = \sigma(\mathcal{A}^m) \subseteq \mathcal{L}_2.$$

Dowodzi to niezależności wektorów X i Y.

Krok 3. Niech $f\colon \mathbb{R}^n \to \mathbb{R}$ i $g\colon \mathbb{R}^m \to \mathbb{R}$ będą borelowskie. Dla dowolnych $E, F \in \mathcal{B}(\mathbb{R})$ przeciwobrazy $f^{-1}(E) \in \mathcal{B}(\mathbb{R}^n)$ i $g^{-1}(F) \in \mathcal{B}(\mathbb{R}^m)$ są borelowskie. Wobec tego

$$\begin{aligned}\mathbb{P}(f(X) \in E,\, g(Y) \in F) &= \mathbb{P}\Big(X \in f^{-1}(E),\, Y \in g^{-1}(F)\Big)\\ &= \mathbb{P}\Big(X \in f^{-1}(E)\Big)\mathbb{P}\Big(Y \in g^{-1}(F)\Big)\\ &= \mathbb{P}(f(X) \in E)\mathbb{P}(g(Y) \in F).\end{aligned}$$

Zatem $f(X)$ i $g(Y)$ są niezależne. □

Rozdział 5

Rozkłady zmiennych losowych

5.1 Rozkład prawdopodobieństwa

Definicja 5.1. *Rozkładem prawdopodobieństwa na* $\mathbb{R}^n$ nazywamy każdą miarę probabilistyczną μ na przestrzeni mierzalnej $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$, czyli miarę taką, że $\mu(\mathbb{R}^n) = 1$.

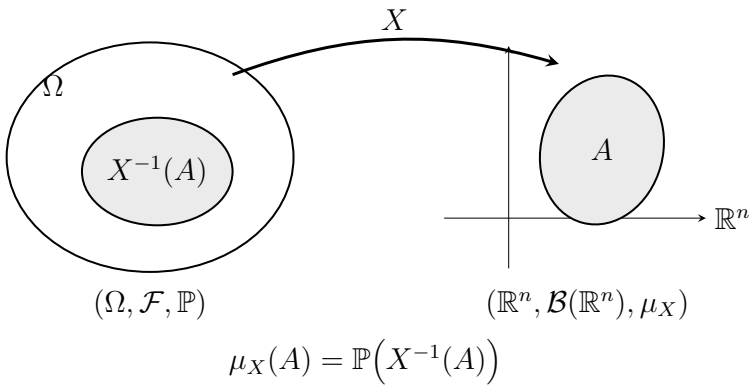
Definicja 5.2. Niech $X\colon \Omega \to \mathbb{R}^n$ będzie wektorem losowym na przestrzeni $(\Omega, \mathcal{F}, \mathbb{P})$. *Rozkład zmiennej losowej* X to miara μ_X określona wzorem

$$\mu_X(A) = \mathbb{P}(X \in A) = \mathbb{P}\Big(X^{-1}(A)\Big), \qquad A \in \mathcal{B}(\mathbb{R}^n).$$

W szczególności

$$\mu_X(\mathbb{R}^n) = \mathbb{P}(X \in \mathbb{R}^n) = \mathbb{P}(\Omega) = 1.$$

Schemat przejścia od zdarzenia w przestrzeni wyników do zbioru wartości zmiennej przedstawia rysunek 5.1.



Rysunek 5.1: Zbiorowi borelowskiemu $A \subseteq \mathbb{R}^n$ odpowiada zdarzenie $X^{-1}(A) \subseteq \Omega$. Rozkład przypisuje mu masę $\mu_X(A) = \mathbb{P}(X^{-1}(A))$.

Przykład 5.1 (Trzy zmienne na odcinku jednostkowym)**.** Rozważmy przestrzeń probabilistyczną

$$(\Omega, \mathcal{F}, \mathbb{P}) = \Big([0,1], \mathcal{B}([0,1]), \lambda\Big),$$

gdzie λ jest miarą Lebesgue'a na $[0,1]$.

a) Zmienna stała. Niech $X(\omega) = c$ dla każdego $\omega \in [0,1]$, gdzie $c \in \mathbb{R}$. Dla $A \in \mathcal{B}(\mathbb{R})$ mamy

$$\mu_X(A) = \mathbb{P}(X \in A) = \begin{cases} 1, & c \in A, \\ 0, & c \notin A. \end{cases}$$

Jest to *miara Diraca w punkcie* c, oznaczana przez δ_c.

b) Indykator. Niech

$$Y(\omega) = \mathbf{1}_{[0,\,2/3)}(\omega).$$

Wówczas dla każdego $A \in \mathcal{B}(\mathbb{R})$

$$\mu_Y(A) = \begin{cases} 1, & 0 \in A,\ 1 \in A, \\ \dfrac{1}{3}, & 0 \in A,\ 1 \notin A, \\ \dfrac{2}{3}, & 0 \notin A,\ 1 \in A, \\ 0, & 0 \notin A,\ 1 \notin A. \end{cases}$$

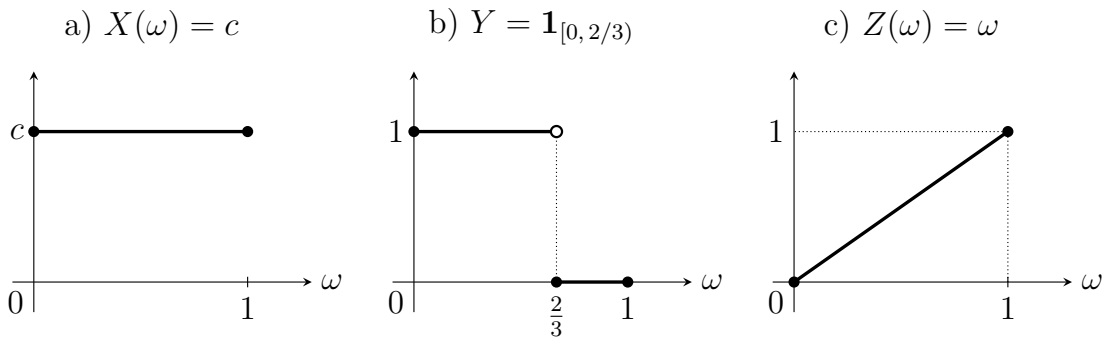
Możemy zatem zapisać

$$\mu_Y = \frac{1}{3}\delta_0 + \frac{2}{3}\delta_1.$$

c) Zmienna identycznościowa. Dla $Z(\omega) = \omega$, $\omega \in [0,1]$, otrzymujemy

$$\mu_Z(A) = \mathbb{P}(Z \in A) = \lambda\Big([0,1] \cap A\Big), \qquad A \in \mathcal{B}(\mathbb{R}).$$

Wykresy zmiennych z tego przykładu pokazano na rysunku 5.2.



Rysunek 5.2: Wykresy trzech zmiennych z przykładu 5.1. Są to wykresy funkcji na $\Omega = [0,1]$.

Przykład 5.2 (Liczba szóstek)**.** Rzucamy niezależnie n razy uczciwą kostką. Niech X oznacza liczbę szóstek w tych rzutach. Wówczas

$$\mu_X(\{k\}) = \mathbb{P}(X = k) = \binom{n}{k} \left(\frac{1}{6}\right)^k \left(\frac{5}{6}\right)^{n-k}, \qquad k = 0, 1, \ldots, n.$$

Zmienna X nie przyjmuje innych wartości, więc na przykład

$$\mu_X\left(\left\{\frac{3}{2}\right\}\right) = 0, \qquad \mu_X(\{n+1\}) = 0.$$

Dla dowolnego $A \in \mathcal{B}(\mathbb{R})$ mamy

$$\begin{aligned}\mu_X(A) &= \sum_{k=0}^{n} \mathbb{P}(X=k)\delta_k(A) \\ &= \sum_{k=0}^{n} \binom{n}{k} \left(\frac{1}{6}\right)^k \left(\frac{5}{6}\right)^{n-k} \delta_k(A).\end{aligned}$$

5.2 Rozkłady dyskretne

Definicja 5.3. Niech $X\colon \Omega \to \mathbb{R}$ będzie zmienną losową. Definiujemy

$$S_X = \{x \in \mathbb{R} : \mu_X(\{x\}) = \mathbb{P}(X=x) > 0\}.$$

Mówimy, że X ma *rozkład dyskretny*, jeżeli

$$\mathbb{P}(X \in S_X) = 1.$$

Uwaga 5.1. Mówimy, że rozkład zmiennej X jest *skupiony na zbiorze* A, jeżeli $A \in \mathcal{B}(\mathbb{R})$ oraz $\mathbb{P}(X \in A) = 1$.

Fakt 5.1. *Zbiór S_X jest co najwyżej przeliczalny.*

Dowód pozostawiono jako ćwiczenie.

Fakt 5.2. *Rozkład dyskretny jest jednoznacznie wyznaczony przez zbiór*

$$S_X = \{x_n : n \in T\},$$

gdzie T jest co najwyżej przeliczalnym zbiorem indeksów, punkty x_n są różne, oraz przez liczby

$$p_n = \mathbb{P}(X = x_n), \qquad n \in T.$$

Wówczas

$$\sum_{n\in T} p_n = 1, \qquad \mu_X(A) = \mathbb{P}(X \in A) = \sum_{\substack{n\in T \\ x_n \in A}} p_n, \quad A \in \mathcal{B}(\mathbb{R}).$$

5.2.1 Przykłady rozkładów dyskretnych

Przykład 5.3 (Rozkład skupiony w jednym punkcie)**.** Dla $a \in \mathbb{R}$ rozkład $\mu = \delta_a$ spełnia

$$\mu(A) = \delta_a(A), \qquad A \in \mathcal{B}(\mathbb{R}).$$

Zmienna o tym rozkładzie spełnia $\mathbb{P}(X = a) = 1$.

Przykład 5.4 (Rozkład dwupunktowy)**.** Niech $p \in [0,1]$ oraz $q = 1-p$. Jeżeli

$$\mathbb{P}(X=1) = p, \qquad \mathbb{P}(X=0) = q,$$

to

$$\mu_X = p\delta_1 + (1-p)\delta_0.$$

Ogólniej, rozkład skupiony na dwóch różnych punktach x_1, x_2 ma postać $\alpha\delta_{x_1} + (1-\alpha)\delta_{x_2}$ dla pewnego $\alpha \in [0,1]$.

Przykład 5.5 (Rozkład Bernoulliego)**.** Rozkład Bernoulliego $B(n,p)$, gdzie $n \geqslant 1$ i $p \in [0,1]$, jest określony przez

$$\mathbb{P}(X=k) = \binom{n}{k} p^k (1-p)^{n-k}, \qquad k = 0, 1, \ldots, n.$$

W przypadkach brzegowych stosujemy konwencję $0^0 = 1$.

Przykład 5.6 (Rozkład geometryczny)**.** Dla $p \in (0,1]$ rozkład geometryczny, oznaczany przez $G(p)$, jest dany wzorem

$$\mathbb{P}(X=k) = (1-p)^{k-1} p, \qquad k = 1, 2, \ldots.$$

Piszemy wówczas $X \sim G(p)$; dla $p = 1$ cała masa jest skupiona w punkcie 1.

Przykład 5.7 (Rozkład Poissona)**.** Rozkład Poissona o parametrze $\lambda \geqslant 0$, oznaczany przez $\mathrm{Pois}(\lambda)$, jest określony przez

$$\mathbb{P}(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}, \qquad k = 0, 1, 2, \ldots.$$

Piszemy $X \sim \mathrm{Pois}(\lambda)$. Dla $\lambda = 0$ rozkład jest równy δ_0.